

Тестовое задание

Forecast DS — прогноз эскалации конфликтной активности
на основе открытых новостных данных (GDELТ)

Позиция: Forecast Data Scientist **Срок выполнения:** 14 дней

Ожидаемое время: ~4 часа **Формат сдачи:** GitHub-репозиторий + защита решения

1. Контекст задачи

Используются открытые данные для раннего мониторинга геополитических рисков. Ваша задача — построить прогнозную модель, которая по историческим новостным сигналам предсказывает эскалацию конфликтной активности в выбранном регионе или стране.

Бизнес-формулировка: «По новостному фону прошлых недель предскажите, будет ли на следующих 1–4 неделях аномальный рост конфликтных событий в выбранной стране».

Задание проверяет навыки работы с open data, построения временных рядов, feature engineering, валидации и воспроизводимости — ключевые компетенции Forecast DS.

2. Что именно предсказываем

2.1. Источник событий

GDELТ Project (бесплатно, без подписки): gdeltproject.org

GDELТ ежедневно парсит мировые новости и извлекает структурированные события с типом (CAMEO-код), страной, датой и тональностью (Goldstein scale).

2.2. Определение конфликтной активности

Еженедельно агрегируйте события эскалации/насилия по выбранной стране:

```
conflict_count_week = COUNT(  
    events WHERE ActionGeo_CountryCode = <ISO>
```

```

AND EventRootCode IN ('18', '19')
AND week = t
)

```

CAMEO Root Code	Тип события
18	Assault (нападения)
19	Fight (столкновения, боевые действия)

2.3. Целевая переменная (на выбор — зафиксируйте в README)

Вариант А — регрессия (рекомендуется для middle)

```
target = conflict_count_week на неделе t+h, h ∈ {1, 2, 3, 4}
```

Выход модели: «На неделе 2025-W35 ожидается 23 конфликтных события [CI: 15–31]»

Вариант В — классификация события (рекомендуется для junior)

```

threshold_t = rolling_mean_52w + 2 × rolling_std_52w
escalation_event_t = 1 if conflict_count_week > threshold_t else 0

```

Выход модели: «Вероятность эскалации на неделе 2025-W35: 0.74»

Пример (условные данные):

- W30: 8 событий → норма
- W31: 11 → норма
- W32: 47 → эскалация (anomaly spike)
- W33: 39 → эскалация
- W34: 12 → норма

Модель на W35: $P(\text{escalation}) = 0.68$ или $\text{count} = 18 \pm 6$

3. Выбор региона

Выберите одну страну и зафиксируйте в README. Рекомендуемые (достаточно данных, но не тривиально):

- **Украина (UP)** — высокая активность, длинная история с 2022

- **Израиль (IS)** — регулярные циклы эскалации
- **Мьянма (BM)** — внутренний конфликт
- **Йемен (YM)** — стабильно высокий фон
- **Судан (SU)** — структурные breaks

Допустима любая страна при условии ≥ 2 лет weekly history и ≥ 30 conflict events в среднем за год. Обоснуйте выбор в README.

4. Данные и источники

4.1. Обязательный источник — GDELT Events

Рекомендуемый способ загрузки (бесплатно):

Способ	Описание	Приоритет
Google BigQuery	Публичный датасет <code>gdelt-bq.gdeltv2.events</code>	★ Рекомендуется
Bulk CSV	data.gdeltproject.org/events/ — daily zip-файлы	Допустимо
GDELT DOC API	TimelineVol для keyword-агрегатов	Дополнительно

Не использовать: GDELT Cloud free tier (100 query units/мес — недостаточно).
Платные API не требуются.

4.2. Пример SQL (BigQuery)

```
SELECT
  DATE_TRUNC(
    DATE(PARSE_TIMESTAMP('%Y%m%d', CAST(SQLDATE AS STRING))),
    WEEK(MONDAY)
  ) AS week_start,
  COUNT(*) AS conflict_count,
  AVG(GoldsteinScale) AS avg_goldstein,
  AVG(AvgTone) AS avg_tone
FROM `gdelt-bq.gdeltv2.events`
WHERE ActionGeo_CountryCode = 'UP'
  AND EventRootCode IN ('18', '19')
  AND SQLDATE BETWEEN 20220101 AND 20251231
```

```
GROUP BY week_start
ORDER BY week_start
```

4.3. Дополнительный открытый источник (минимум 1)

- **Google Trends** — запросы типа «war», «conflict [country]» (`pytrends`)
- **ACLED** — curated conflict data (free for researchers, registration required)
- **World Bank / IMF** — макро-индикаторы как external regressors
- **GDELT DOC TimelineVol** — объём новостей по ключевым словам

4.4. Требования к данным

Параметр	Требование
Период истории	Минимум 2 года (рекомендуется 3+)
Частота	Недельная агрегация
Hold-out	Последние 12 недель — не использовать при обучении
Документирование	URL источника, дата скачивания, версия

5. Feature engineering

Минимальный набор фич (реализуйте и обоснуйте в README):

Группа	Примеры фич
Лаги target	<code>conflict_count_lag1</code> , <code>lag2</code> , <code>lag4</code> , <code>lag12</code>
Rolling stats	<code>rolling_mean_4w</code> , <code>rolling_std_12w</code> , <code>rolling_max_8w</code>
Тональность	<code>avg_goldstein</code> , <code>avg_tone</code> , <code>goldstein_volatility</code>
Объём новостей	<code>total_events_country</code> , <code>news_volume_change_wow</code>
Календарь	<code>week_of_year</code> , <code>month</code> , <code>is_holiday</code> (country-specific)
External	<code>google_trends_score</code> , <code>macro_indicator</code> (lagged!)
Trend	<code>weeks_since_major_spike</code> , <code>cumulative_conflict_12w</code>

Data leakage: запрещено использовать future values в фичах. Нормализация и target encoding — только на train fold. External regressors должны быть доступны на момент прогноза (учитывайте задержки публикации).

6. Модели

Обучите и сравните минимум 3 модели:

#	Модель	Назначение
1	Baseline: seasonal naive или rolling mean	Обязательный floor
2	Prophet / ETS / ARIMA (на выбор)	Statistical benchmark
3	XGBoost / LightGBM с лаговыми фичами	ML benchmark

Для варианта В (классификация): logistic regression или XGBClassifier как ML-модель.

7. Валидация

7.1. Метод

- Rolling / walk-forward cross-validation — **обязательно**
- Random split **запрещён**
- Hold-out: последние 12 недель
- Горизонт прогноза: 1–4 недели (direct или recursive — зафиксируйте)

7.2. Метрики

Тип target	Метрики
Регрессия (count)	MASE, sMAPE, RMSE — vs baseline
Классификация (event)	Precision, Recall, F1, Brier score, ROC-AUC

7.3. Обязательная таблица результатов

Model	MASE	sMAPE	RMSE	vs Baseline
Baseline (naive)	1.00	...	...	—

Model	MASE	sMAPE	RMSE	vs Baseline
Prophet	...	...	...	+12%
XGBoost	...	...	...	+18%

8. Deliverables

8.1. Структура репозитория

Рекомендуемая структура — можно адаптировать под свой подход, главное чтобы решение было воспроизводимым по README.

```
forecast-escalation/
├─ README.md
├─ requirements.txt
├─ src/                # или notebooks/ – на ваш выбор
├─ data/              # raw/processed (raw в .gitignore)
├─ outputs/
│   ├─ metrics.json
│   ├─ forecast.csv
│   └─ figures/
```

8.2. README must include

1. Выбранная страна и обоснование
2. Формула target (A или B) — точная, воспроизводимая
3. Список источников с URL и датой скачивания
4. Схема пайплайна (текст или diagram)
5. Таблица метрик всех моделей vs baseline
6. 3 главных вывода: что работает, что нет, что улучшить
7. Limitations: задержки GDELT, selection bias, structural breaks
8. Идеи улучшения (опционально): что бы вы добавили при большем времени или доступе к prod-данным

8.3. Формат forecast.csv

```
country,forecast_week,horizon,target_type,predicted_value,predicted_prob,ci_lower,ci_upper
Ukraine,2025-W35,1,count,23,,18,28,xgboost
Ukraine,2025-W35,1,event,,0.74,0.58,0.87,xgboost
```

8.4. Формат защиты

Сдача происходит в формате защиты решения (онлайн или очно, ~30 мин):

1. Кратко: постановка задачи, выбор страны и target
2. Демо пайплайна: данные → фичи → модели → метрики
3. Разбор результатов: что сработало, limitations, сравнение с baseline
4. Идеи улучшения — приветствуются, даже если не реализованы в коде
5. Ответы на вопросы команды

Заранее пришлите ссылку на GitHub-репозиторий (public или invite). README должно быть достаточно для воспроизведения без устных пояснений.

9. Критерии оценки (100 баллов)

Балл	Блок	Критерий
10	Постановка задачи	Чёткий target, страна, формула эскалации, нет ambiguity
15	Open data	GDELT через BigQuery/bulk, lineage, обработка ошибок
15	Feature engineering	Лаги, rolling, tone, external regressor, calendar
25	Валидация	Rolling CV, hold-out 12w, no leakage, vs baseline
15	Модели	3 модели, ML не хуже baseline без объяснения
10	Код	Запускается по README, структура, requirements.txt
10	Коммуникация	Выводы, limitations, идеи улучшения, honesty about what news can/can't predict

10. Вопросы на защите

На защите (~30 мин) обсудим решение и зададим вопросы, например:

1. Почему вы выбрали именно этот порог эскалации (2σ)?
2. Где в вашем пайплайне мог бы возникнуть data leakage?
3. Почему новости могут не предсказывать эскалацию?
4. Что бы вы сделали, если GDELT перестал обновляться?
5. Когда ваша ML-модель хуже seasonal naïve — и это нормально?

11. Ограничения и FAQ

Вопрос	Ответ
Можно ли использовать ChatGPT/Claude?	Да, как инструмент. Укажите в README, где использовали AI.
Можно ли ACLED вместо GDELT?	ACLED — дополнительный источник. GDELT — обязателен как primary.
Нужен ли Docker?	Нет, но + к оценке.
Куда слать результат?	GitHub link (public или invite) на email рекрутера. Защита назначается после проверки репозитория.
Можно ли предложить улучшения?	Да. Опишите идеи в README или на защите — даже без реализации в коде. Это плюс к оценке.
Можно задавать вопросы?	Да, в течение 24 ч после получения задания.

Срок: 14 дней с момента получения.

Объём: ~4 часа чистого времени.

Язык: README и комментарии — русский или английский (на выбор).